

Fouille de Données Massives
TD – Adaptation de Domaine – Corrigé
M2 Informatique - SISE (2026-2027)

Guillaume Metzler
Institut de Communication (ICOM)
Université de Lyon, Université Lumière Lyon 2
Laboratoire ERIC UR 3083, Lyon, France
`guillaume.metzler@univ-lyon2.fr`

Résumé. Corrigé détaillé du TD sur l'adaptation de domaine (séance 6). Chaque solution est numérotée comme l'énoncé correspondant dans `td_da.pdf`.

1 Fondamentaux : covariate shift et repondération

Solution – Identifier l'hypothèse de correspondance

- (a) **Covariate shift.** Les profils de patients diffèrent ($P_S(X) \neq P_T(X)$, âge différent), mais la manifestation clinique de la pathologie, conditionnellement au profil, est supposée identique ($P(Y | X)$ inchangé).
- (b) **Concept shift.** La notion même de « clic » (et donc la relation entre le profil utilisateur/contenu et le comportement observé) a changé de nature entre 2015 et 2025 : ni $P(X | Y)$ ni $P(Y | X)$ ne sont stables au sens des définitions du cours.
- (c) **Biais de sélection d'échantillon.** Il existe une distribution « vraie » sous-jacente des températures, mais le capteur d'entraînement exclut systématiquement certaines valeurs (les extrêmes) via une variable de sélection ξ liée à la valeur mesurée elle-même.

Solution – Régression pondérée, Exercice 1.2

- (a) $w(x) = p_t(x)/p_s(x)$ avec $p_s(x) \propto \exp(-(x+1)^2/2)$, $p_t(x) \propto \exp(-(x-1)^2/2)$ (même variance 1) :

$$w(x) = \exp\left(-\frac{(x-1)^2}{2} + \frac{(x+1)^2}{2}\right) = \exp\left(\frac{(x+1)^2 - (x-1)^2}{2}\right) = \exp(2x).$$

- (b) $w(-0.5) = \exp(-1) \approx 0.3679$.
- (c) $w(1.5) = \exp(3) \approx 20.0855$. Le poids explose très vite dès que x s'éloigne de la zone source (autour de $x = -1$) pour se rapprocher de la zone cible (autour de $x = +1$) : w croît de façon exponentielle, ce qui est le symptôme classique d'un faible recouvrement de support — quelques points source « typiquement cible » héritent d'un poids disproportionné.
- (d) Cf. Exercice 3.1 du cours : en écrivant $\Delta = \text{diag}(\sqrt{w_1}, \dots, \sqrt{w_m})$, le problème devient $\min_{\beta} \|\Delta X \beta^\top - \Delta Y\|_2^2$, moindres carrés ordinaires sur les données trans-

formées, dont la solution est

$$\beta^* = [(\Delta X)^\top \Delta X]^{-1} (\Delta X)^\top \Delta Y = [X^\top \Delta^2 X]^{-1} X^\top \Delta^2 Y.$$

Solution – Effective Sample Size, Exercice 1.3

- (a) $w = (1, 1, 1, 1)$: $\text{ESS} = \frac{4^2}{4} = 4 = m$. Tous les poids étant égaux, on utilise l'intégralité de l'échantillon — situation idéale (proche du cas non repondéré).
- (b) $w = (10, 0.1, 0.1, 0.1)$: $\sum w_i = 10.3$, $\sum w_i^2 = 100 + 0.03 = 100.03$, donc $\text{ESS} = \frac{10.3^2}{100.03} = \frac{106.09}{100.03} \approx 1.06$. Bien que $m = 4$, on « n'utilise effectivement » qu'environ 1 point : un seul poids domine totalement les autres. C'est exactement le symptôme de supports peu recouvrants illustré Figure 3.5 du cours : quelques points source reçoivent un poids énorme et l'estimateur repondéré devient presque équivalent à un estimateur ponctuel, donc à variance très élevée.
- (c) Par Cauchy-Schwarz appliqué à (w_i) et $(1)_i$: $(\sum_i w_i \cdot 1)^2 \leq (\sum_i w_i^2)(\sum_i 1^2) = m \sum_i w_i^2$, donc $\text{ESS} = \frac{(\sum w_i)^2}{\sum w_i^2} \leq m$, avec égalité ssi tous les w_i sont égaux. Pour la borne inférieure, comme $w_i \geq 0$, $(\sum_i w_i)^2 = \sum_i w_i^2 + 2 \sum_{i < j} w_i w_j \geq \sum_i w_i^2$ (le second terme est positif ou nul), donc $\text{ESS} \geq 1$, avec égalité ssi un seul poids est non nul.

2 Estimer le ratio de densités

Solution – Densité paramétrique vs. noyaux, Exercice 2.1

- (a) $\hat{\mu}_s = \frac{-1.2-0.9-1.1-0.8}{4} = -1.0$, et $\hat{\sigma}_s^2 = \frac{1}{4} \sum_i (x_i - \hat{\mu}_s)^2 = \frac{0.04+0.01+0.01+0.04}{4} = 0.025$. De même $\hat{\mu}_t = \frac{0.8+1.3+1.0}{3} \approx 1.0333$ et $\hat{\sigma}_t^2 \approx 0.0422$.
- (b) $\hat{p}_s(x_1) = \frac{1}{\sqrt{2\pi \cdot 0.025}} \exp\left(-\frac{(-1.2+1)^2}{2 \cdot 0.025}\right) \approx 2.523 \times \exp(-0.8) \approx 1.134$. $\hat{p}_t(x_1) = \frac{1}{\sqrt{2\pi \cdot 0.0422}} \exp\left(-\frac{(-1.2-1.0333)^2}{2 \cdot 0.0422}\right) \approx 1.942 \times \exp(-59.1) \approx 3.5 \times 10^{-26}$. D'où $\hat{w}(x_1) = \hat{p}_t(x_1)/\hat{p}_s(x_1) \approx 3 \times 10^{-26} \approx 0$. **Interprétation** : $x_1 = -1.2$ est totalement excentré par rapport à la population cible estimée (centrée en 1.03, écart-type 0.21) : sous le modèle gaussien, la probabilité que ce point vienne de la cible est numériquement nulle. En pratique, ce genre de sous/sur-flottant justifie de travailler en log-vraisemblance et de *clipper* les poids extrêmes (cf. Exercice 1.3).
- (c) Non normalisé, $\sum_{x_i \in S_X} k(-1, x_i)$ avec $\sigma = 0.3$ (donc $2\sigma^2 = 0.18$) :

x_i	$(x_i - (-1))^2$	$k(-1, x_i) = \exp(-(x_i + 1)^2/0.18)$
-1.2	0.04	0.80
-0.9	0.01	0.95
-1.1	0.01	0.95
-0.8	0.04	0.80

Somme $\approx 0.80 + 0.95 + 0.95 + 0.80 = 3.49$ (à 10^{-2} près). Contrairement à l'ap-

proche paramétrique, cette estimation reste « raisonnable » car elle n'extrapole pas au-delà de la forme observée des données.

Solution – Kernel Mean Matching, Exercice 2.2

- (a) Le problème non contraint $\min_w w^\top K w - 2\kappa^\top w$ est convexe quadratique (car K est une matrice de Gram, semi-définie positive). La condition du premier ordre est $\nabla_w (w^\top K w - 2\kappa^\top w) = 2Kw - 2\kappa = 0 \iff w^* = K^{-1}\kappa$.
- (b) $\kappa_i = \frac{m}{n} \sum_{x'_j \in T_X} k(x_i, x'_j)$ est (à la constante m/n près) une mesure de similarité moyenne entre le point source x_i et l'ensemble de la cible : un point source « typique de la cible » aura un κ_i élevé. La normalisation m/n compense la différence de taille entre échantillon source (m points) et cible (n points), pour que w^* reste à la bonne échelle (poids moyen ≈ 1 plutôt que $\approx n/m$).
- (c) Les contraintes garantissent que w reste interprétable comme un ratio de densités : $w \geq 0$ car un ratio de densités est positif, et $\sum_i w_i = m$ assure que la « masse totale » repondérée de la source reste comparable à sa masse d'origine (analogue discret de $\int w(x)p_s(x)dx = \int p_t(x)dx = 1$). Sans ces contraintes, $w^* = K^{-1}\kappa$ pourrait prendre des valeurs négatives ou une échelle arbitraire, perdant toute interprétation probabiliste : on obtiendrait un simple vecteur de coefficients de régression, pas une repondération valide.

Solution – Classifieur de domaine, Exercice 2.3

- (a) Comme dans l'exercice du cours (Exercice 3.2), on maximise point par point $g(\phi) = p_s(x) \log \phi + p_t(x) \log(1 - \phi) : g'(\phi) = p_s(x)/\phi - p_t(x)/(1 - \phi) = 0 \iff \phi^*(x) = \frac{p_s(x)}{p_s(x) + p_t(x)}$ (et $g'' < 0$, donc c'est bien un maximum).
- (b) $\frac{1}{\phi^*(x)} = \frac{p_s(x) + p_t(x)}{p_s(x)} = 1 + \frac{p_t(x)}{p_s(x)}$, donc $w(x) = \frac{1}{\phi^*(x)} - 1$ — la même formule que dans le cours, mais construite ici avec la convention $\phi(x) = \mathbb{P}(S | x)$ (et non $\mathbb{P}(T | x)$).
- (c) En appliquant la formule $w = 1/\phi - 1$ à un classifieur entraîné avec $\phi(x) = \mathbb{P}(T | x)$ (la convention du cours), le data scientist calcule en réalité

$$\frac{1}{\mathbb{P}(T | x)} - 1 = \frac{1 - \mathbb{P}(T | x)}{\mathbb{P}(T | x)} = \frac{\mathbb{P}(S | x)}{\mathbb{P}(T | x)} \approx \frac{p_s(x)}{p_t(x)} = \frac{1}{w(x)}.$$

Il calcule donc l'**inverse** du poids voulu : il sous-pondère les points source « typiquement cible » (ceux qu'on veut justement amplifier) et sur-pondère les points « typiquement source » (ceux qui apportent le moins d'information sur la cible). C'est un bug silencieux — le code s'exécute sans erreur, mais dégrade activement l'adaptation. D'où l'importance de toujours vérifier la convention avant d'implémenter (cf. mise en garde du cours).

3 Bornes de généralisation

Solution – $\mathcal{H}$ -divergence, Exercice 3.1

- (a) $h_1(x) = \mathbb{1}[x \leq 2]$ vaut 1 en $x = 1, 2$ (tous les points source) et 0 en $x = 3, 4$ (tous les points cible). Donc $\mathbb{P}_{D_S}[h_1 = 1] = 1$ et $\mathbb{P}_{D_T}[h_1 = 1] = 0$.
- (b) Avec $h_1 : 2|1 - 0| = 2$.
- (c) $h_2(x) = \mathbb{1}[x \leq 3]$ vaut 1 en $x = 1, 2, 3$, donc $\mathbb{P}_{D_S}[h_2 = 1] = 1$ (les deux points source sont ≤ 3) et $\mathbb{P}_{D_T}[h_2 = 1] = \mathbb{P}(x = 3) = 0.5$ (un seul des deux points cible, $x = 3$, vérifie $x \leq 3$). D'où $2|1 - 0.5| = 1$. Le classifieur h_1 atteint donc la plus grande valeur : $d_{\mathcal{H}}(D_S, D_T) = \max(2, 1) = 2$. C'est cohérent avec le fait que h_1 sépare *parfaitement* source et cible (erreur de classification nulle), tandis que h_2 ne les sépare qu'imparfaitement.

Solution – Lecture de la borne de Ben-David, Exercice 3.2

- (a) $\hat{d}_{\mathcal{H}}(S_X, T_X) = 2(1 - 2\text{err}(\phi))$, où $\text{err}(\phi)$ est l'erreur du meilleur classifieur de domaine entraîné sur S_X vs. T_X .
- (b) $\hat{d}_{\mathcal{H}} = 2(1 - 2 \times 0.42) = 2 \times 0.16 = 0.32$.
- (c) $R_T(h) \leq R_S(h) + \frac{1}{2}\hat{d}_{\mathcal{H}} + \lambda_{\mathcal{H}} = 0.05 + 0.16 + 0.03 = 0.24$.
- (d) Avec $\text{err}(\phi') = 0.08 : \hat{d}'_{\mathcal{H}} = 2(1 - 0.16) = 1.68$, ce qui donne une borne $0.05 + 0.84 + 0.03 = 0.92$. Un classifieur de domaine *plus performant* signale des domaines *plus facilement séparables*, donc *plus éloignés* au sens de $\mathcal{H}$: c'est un signal que le problème de transfert est intrinsèquement plus difficile dans ce second cas. La borne obtenue (proche de 1, le risque maximal pour une perte 0/1) est ici quasiment **non informative** : elle ne garantit presque rien sur $R_T(h)$. Ce résultat illustre bien le compromis au cœur de la borne de Ben-David : un bon transfert nécessite *à la fois* un faible risque source *et* des domaines peu séparables.

Solution – Rôle du KL, Exercice 3.3

- (a) Avec $m = 500$, $\delta = 0.05$, $\log(1/\delta) = \log(20) \approx 2.996$:

$$\text{Borne}(Q_1) = 0.10 + 0.04 + \sqrt{\frac{2.0 + 2.996}{500}} = 0.14 + \sqrt{0.00999} \approx 0.14 + 0.10 = 0.24.$$

$$\text{Borne}(Q_2) = 0.06 + 0.03 + \sqrt{\frac{45.0 + 2.996}{500}} = 0.09 + \sqrt{0.09599} \approx 0.09 + 0.31 = 0.40.$$

- (b) Au vu du seul risque source, Q_2 ($R_S = 0.06$) semble préférable à Q_1 ($R_S = 0.10$). Mais la borne complète inverse le classement : Q_1 (borne ≈ 0.24) est préférable à Q_2 (borne ≈ 0.40), car le coût en complexité ($\text{KL} = 45$ contre 2) de Q_2 domine largement son gain en risque empirique.
- (c) C'est exactement le compromis biais/complexité rencontré ailleurs en apprentissage statistique (cf. arbitrage biais-variance, ou le rôle du terme de régularisation/KL dans les certificats PAC-Bayésiens pour les méthodes d'ensemble) : un modèle qui « colle » très près des données d'entraînement (ici, un posterior très concentré, loin du prior) n'est fiable que si sa complexité reste sous contrôle ; si-

non, son bon score empirique ne se généralise pas et la borne — donc la garantie théorique de performance — s'en trouve dégradée.

4 Ouverture : méthodes récentes

Solution – DANN et Gradient Reversal Layer, Exercice 4.1

- (a) G_f et G_y minimisent $\mathcal{L}_y - \lambda \mathcal{L}_d$ (ils veulent bien classer les labels *et* rendre $\mathcal{L}_d$ la plus grande possible, donc minimisent son opposé), tandis que G_d minimise $\mathcal{L}_d$ seul (il veut au contraire bien discriminer les domaines). C'est un jeu à somme non nulle entre (G_f, G_y) et G_d .
- (b) En rétropropagation standard, tous les morceaux du réseau feraient une descente de gradient sur la même perte totale, donc G_f *minimiserait* aussi $\mathcal{L}_d$ comme G_d — ce qui est l'inverse de ce qu'on veut. En multipliant le gradient de $\mathcal{L}_d$ par $-\lambda$ uniquement lors de sa traversée de G_f , on transforme localement, du point de vue de G_f , une descente de gradient sur $\mathcal{L}_d$ en une *montée* de gradient (donc une maximisation), sans changer l'algorithme d'optimisation global (toujours une simple descente de gradient) ni ajouter de boucle d'optimisation imbriquée — une astuce purement calculatoire, très efficace en pratique.
- (c) Il minimise (du point de vue de G_d) l'erreur du classifieur de domaine sur les features $G_f(x)$, c'est-à-dire minimise $\text{err}(\phi)$ dans l'espace des features appris. Or, la borne de Ben-David dépend de $\hat{d}_{\mathcal{H}} = 2(1 - 2\text{err}(\phi))$: *maximiser* $\text{err}(\phi)$ (ce vers quoi G_f est poussé par le gradient inversé, en rendant les domaines indiscernables) revient à *minimiser* $\hat{d}_{\mathcal{H}}$, donc directement le second terme de la borne de généralisation.
- (d) Quand les proportions de classes diffèrent fortement entre source et cible (target shift marqué), forcer $\hat{d}_{\mathcal{H}}(S, T) \rightarrow 0$ (features totalement invariantes au domaine) peut détruire l'information nécessaire à la discrimination des classes elles-mêmes, augmentant en réalité le terme irréductible $\lambda_{\mathcal{H}}$ (cf. Zhao et al., 2019, vu en cours) : DANN peut alors dégrader la performance cible malgré un classifieur de domaine « trompé » avec succès.