

Fouille de Données Massives
TD – Adaptation de Domaine
M2 Informatique - SISE (2026-2027)

Guillaume Metzler
Institut de Communication (ICOM)
Université de Lyon, Université Lumière Lyon 2
Laboratoire ERIC UR 3083, Lyon, France
`guillaume.metzler@univ-lyon2.fr`

Résumé. Ce TD reprend et prolonge les notions du cours (séance 6) : repondération d'instances sous covariate shift, estimation du ratio de densités (KDE, KMM, classifieur de domaine), puis bornes de généralisation ($\mathcal{H}\Delta\mathcal{H}$, PAC-Bayes) et un aperçu des méthodes profondes récentes (DANN). Les exercices marqués (**Application**) demandent un calcul numérique court ; ceux marqués (**Preuve**) une démonstration. La correction est fournie dans un document séparé (`td_da_solutions.pdf`).

1 Fondamentaux : covariate shift et repondération

Exercice 1.1 (Identifier l'hypothèse de correspondance). Pour chacune des situations suivantes, indiquez laquelle des quatre hypothèses vues en cours (covariate shift, target shift, biais de sélection, concept shift) est la plus plausible, et justifiez en une phrase.

- (a) Un hôpital A forme un modèle de dépistage sur ses patients (population plutôt âgée) ; l'hôpital B, dans une autre région, a une population plus jeune, mais la même pathologie se manifeste de la même façon cliniquement dans les deux populations.
- (b) Une plateforme de recommandation de films est entraînée sur des clics de 2015, où les utilisateurs préféraient les DVD physiques loués en magasin ; en 2025, les mêmes types de contenus sont préférés, mais la manière de les consommer (SVOD) a totalement changé la notion même de « clic ».
- (c) Un capteur de température, mal calibré, sous-échantillonne systématiquement les mesures extrêmes lors de la collecte des données d'entraînement, alors que le capteur de production (bien calibré) ne souffre pas de ce biais.

Exercice 1.2 (Régression pondérée – calcul explicite). (**Application**) On considère $P_S(X) = \mathcal{N}(-1, 1)$, $P_T(X) = \mathcal{N}(1, 1)$, et le modèle $P_S(Y | X = x) = P_T(Y | X = x) = \mathcal{N}(|x|, \sigma^2)$ (covariate shift).

- (a) Rappelez la définition de $w(x) = p_t(x)/p_s(x)$ et montrez que, dans ce cas précis, $w(x) = \exp(2x)$.
- (b) On observe un unique point source $x_1 = -0.5$. Calculez $w(x_1)$.
- (c) On observe un second point source $x_2 = 1.5$. Calculez $w(x_2)$ et comparez à $w(x_1)$. Que constatez-vous sur le comportement de w loin de la zone où vivent les données source ?
- (d) (**Preuve**) Pour $X \in \mathbb{R}^{m \times p}$, $Y \in \mathbb{R}^m$, et $\Delta = \text{diag}(\sqrt{w_1}, \dots, \sqrt{w_m})$, retrouvez la solution β^* du problème de régression pondérée $\min_{\beta} \sum_i w_i (x_i \beta^\top - y_i)^2$.

Exercice 1.3 (Effective Sample Size). (**Application**) Un problème pratique des méthodes instance-based : si quelques poids w_i dominent tous les autres, on n'utilise « effectivement » qu'une poignée de points source, même si m est grand. On mesure cela par la taille d'échantillon effective :

$$\text{ESS}(w) = \frac{(\sum_{i=1}^m w_i)^2}{\sum_{i=1}^m w_i^2}.$$

- (a) Calculez $\text{ESS}(w)$ pour $m = 4$ poids égaux $w = (1, 1, 1, 1)$. Commentez.
- (b) Calculez $\text{ESS}(w)$ pour $w = (10, 0.1, 0.1, 0.1)$. Commentez, en particulier au regard de la Figure 3.5 du cours (supports peu recouvrants).
- (c) (**Preuve**) Montrez que $1 \leq \text{ESS}(w) \leq m$ pour tout vecteur de poids positifs w (indication : utilisez l'inégalité de Cauchy-Schwarz pour la borne supérieure).

2 Estimer le ratio de densités

Exercice 2.1 (Densité paramétrique vs. noyaux). (**Application**) On dispose de $S_X = \{-1.2, -0.9, -1.1, -0.8\}$ et $T_X = \{0.8, 1.3, 1.0\}$.

- (a) Calculez les estimateurs de moyenne et variance empiriques $(\hat{\mu}_s, \hat{\sigma}_s^2)$ et $(\hat{\mu}_t, \hat{\sigma}_t^2)$ utilisés par l'approche paramétrique gaussienne (méthode du maximum de vraisemblance).
- (b) En déduire $\hat{w}(x_i) = \hat{p}_t(x_i)/\hat{p}_s(x_i)$ pour $x_1 = -1.2$.
- (c) (**Preuve**) Pour un noyau gaussien $k(x, x') = \exp(-(x - x')^2/2\sigma^2)$, écrivez l'estimateur de densité par noyaux $\hat{p}_s(x)$ non normalisé pour l'échantillon S_X ci-dessus, et donnez sa valeur en $x = -1$ pour $\sigma = 0.3$ (à 10^{-2} près).

Exercice 2.2 (Kernel Mean Matching). (**Preuve**) On rappelle que KMM résout $w^* = \arg \min_{w \geq 0, w^\top \mathbf{1} = m} w^\top K w - 2\kappa^\top w$, où $K_{ij} = k(x_i, x_j)$, $\kappa_i = \frac{m}{n} \sum_j k(x_i, x'_j)$.

- (a) Sans la contrainte $w \geq 0$ ni $w^\top \mathbf{1} = m$, écrivez la condition d'optimalité du premier ordre du problème $\min_w w^\top K w - 2\kappa^\top w$ et donnez la solution non contrainte w^* (en supposant K inversible).
- (b) Que représente κ_i intuitivement ? Pourquoi la normalisation par m/n est-elle nécessaire ?
- (c) Pourquoi le problème original impose-t-il $w \geq 0$ et $\sum_i w_i = m$? Que se passerait-il pour l'interprétation de w comme ratio de densités si l'on retirait ces contraintes ?

Exercice 2.3 (Classifieur de domaine). (**Preuve**) On adopte ici la convention *inverse* de celle du cours : $\phi(x) = \hat{\mathbb{P}}(\text{domaine} = S \mid X = x)$ (et non T). On entraîne ϕ par minimisation de l'entropie croisée

$$\phi^* = \arg \max_{\phi} \mathbb{E}_{P_S(X)} [\log \phi(X)] + \mathbb{E}_{P_T(X)} [\log(1 - \phi(X))].$$

- (a) Montrez que $\phi^*(x) = p_s(x)/(p_s(x) + p_t(x))$.
- (b) En déduire l'expression de $w(x) = p_t(x)/p_s(x)$ en fonction de $\phi^*(x)$ uniquement.
- (c) Un data scientist utilise par erreur un classifieur de domaine avec la convention du cours ($\phi(x) = \hat{\mathbb{P}}(T \mid x)$) mais applique la formule $w(x) = 1/\phi(x) - 1$ de cet exercice. Quelle erreur commet-il, et quel est l'effet pratique sur les poids obtenus (sous-estimation ou surestimation de l'importance des zones « typiquement cible ») ?

3 Bornes de généralisation

Exercice 3.1 ($\mathcal{H}$ -divergence sur un exemple jouet). (**Application**) On considère $\mathcal{X} = \{1, 2, 3, 4\}$, avec D_S uniforme sur $\{1, 2\}$ et D_T uniforme sur $\{3, 4\}$. On prend $\mathcal{H} = \{h_1, h_2\}$ où $h_1(x) = \mathbb{1}[x \leq 2]$ et $h_2(x) = \mathbb{1}[x \leq 3]$.

- (a) Calculez $\mathbb{P}_{D_S}[h_1(x) = 1]$ et $\mathbb{P}_{D_T}[h_1(x) = 1]$.
- (b) En déduire une valeur de $d_{\mathcal{H}}(D_S, D_T)$ obtenue avec h_1 (rappel : $d_{\mathcal{H}}(D_S, D_T) = 2 \sup_{h \in \mathcal{H}} |\mathbb{P}_{D_S}[h = 1] - \mathbb{P}_{D_T}[h = 1]|$).
- (c) Refaites le calcul avec h_2 . Quel est le classifieur de $\mathcal{H}$ qui « sépare le mieux » source et cible ici, et quelle est la valeur de $d_{\mathcal{H}}(D_S, D_T)$ pour cette classe $\mathcal{H} = \{h_1, h_2\}$?

Exercice 3.2 (Lecture de la borne de Ben-David). (**Application**) On suppose qu'un data scientist entraîne un classifieur h et mesure $R_S(h) = 0.05$ (risque source), un classifieur de domaine avec un taux d'erreur $\text{err}(\phi) = 0.42$ pour séparer S_X de T_X , et estime (par une méthode indépendante) $\lambda_{\mathcal{H}} \approx 0.03$.

- (a) Rappelez la formule reliant $\text{err}(\phi)$ (erreur du meilleur classifieur de domaine) et le proxy empirique $\hat{d}_{\mathcal{H}}(S_X, T_X)$.
- (b) Calculez la valeur numérique de $\hat{d}_{\mathcal{H}}(S_X, T_X)$ pour cet exemple.
- (c) En déduire une borne numérique sur $R_T(h)$ à l'aide du théorème de Ben-David et al.
- (d) Un second data scientist obtient un classifieur de domaine bien plus performant, $\text{err}(\phi') = 0.08$, sur les mêmes données. Que peut-on en conclure sur la difficulté du problème de transfert dans ce second cas ? La borne obtenue est-elle plus ou moins informative ?

Exercice 3.3 (Comprendre le rôle du KL dans la borne PAC-Bayésienne). (**Application**) On propose deux posteriors Q_1 et Q_2 sur une même classe $\mathcal{H}$, avec les valeurs suivantes (unités arbitraires, $m = 500$, $\delta = 0.05$) :

	$R_S(Q)$	$\text{dis}_T(Q)/2$	$\text{KL}(Q\ P)$
Q_1	0.10	0.04	2.0
Q_2	0.06	0.03	45.0

On néglige ici le terme $\lambda(Q)$ (supposé identique et faible pour les deux) et on prend le terme de complexité sous la forme simplifiée $\sqrt{(\text{KL}(Q\|P) + \log(1/\delta))/m}$.

- (a) Calculez la borne PAC-Bayésienne approchée pour Q_1 puis pour Q_2 .
- (b) Quel posterior semble préférable au vu du risque source seul ? Et au vu de la borne complète ?
- (c) En une phrase, expliquez pourquoi ce phénomène illustre le compromis biais/complexité déjà rencontré dans d'autres contextes d'apprentissage statistique.

4 Ouverture : méthodes récentes

Exercice 4.1 (DANN et Gradient Reversal Layer). (**Preuve/Réflexion**)

- (a) DANN entraîne conjointement un extracteur de features G_f , un classifieur de labels G_y et un classifieur de domaine G_d . Écrivez (sans détailler l'architecture) la fonction objectif combinée que G_f et G_y cherchent à *minimiser*, et celle que G_d cherche à minimiser, en notant $\mathcal{L}_y$ la perte de classification des labels et $\mathcal{L}_d$ la perte du classifieur de domaine.
- (b) Le Gradient Reversal Layer multiplie le gradient de $\mathcal{L}_d$ par $-\lambda$ (avec $\lambda > 0$) lorsqu'il traverse G_f dans la rétropropagation. Expliquez pourquoi cela permet d'entraîner G_f à *maximiser* $\mathcal{L}_d$ tout en gardant une seule passe de descente de gradient pour l'ensemble du réseau.
- (c) Reliez cette procédure à la borne de Ben-David vue en cours : quelle quantité de cette borne DANN cherche-t-il concrètement à minimiser via G_d ?
- (d) **(Réflexion)** D'après la mise en garde de Zhao et al. (2019) vue en cours, dans quelle situation (en termes de proportions de classes) le principe même de DANN peut-il devenir contre-productif ?